

LAPORAN PROYEK TAHAP 1

Project Akhir Individu Decision Support System

Task NLP: Summarization

Komponen	Keterangan
Nama Repository	BooookScore
URL Repository	https://github.com/lilakk/BooookScore
Paper Rujukan Utama	https://arxiv.org/pdf/2310.00785.pdf
Deadline Kelas B	Senin, 11 Mei 2026, 23.59 WIB

1. Pendahuluan

Summarization merupakan salah satu task penting dalam Natural Language Processing (NLP) yang bertujuan menghasilkan ringkasan dari teks panjang dengan tetap mempertahankan informasi utama. Task ini banyak digunakan untuk membantu pengguna memahami isi dokumen secara cepat, terutama ketika dokumen memiliki ukuran besar, seperti artikel ilmiah, laporan bisnis, berita, dokumen hukum, transkrip rapat, hingga buku.

Dalam konteks Decision Support System (DSS), summarization memiliki peran penting karena sistem pendukung keputusan sering berhadapan dengan informasi yang panjang, kompleks, dan tidak terstruktur. Dengan adanya summarization, pengambil keputusan dapat memperoleh inti informasi secara lebih cepat, sehingga proses analisis, evaluasi alternatif, dan pengambilan keputusan dapat dilakukan dengan lebih efisien.

Repository yang dipilih dalam Project Tahap 1 ini adalah BooookScore. Repository ini dipilih karena secara langsung membahas task book-length summarization, yaitu peringkasan teks sangat panjang dalam bentuk buku. BooookScore relevan dengan perkembangan NLP modern karena menggunakan Large Language Models (LLMs) dan prompt methods untuk menghasilkan serta mengevaluasi ringkasan.

Alasan utama pemilihan repository

BooookScore sesuai dengan kebutuhan tugas karena menyediakan repository GitHub, code, contoh data, prompt, hasil ringkasan, serta paper rujukan utama yang jelas dan saling berhubungan.

2. Nama URL/GitHub dan Nama Pemilik

Komponen	Keterangan
Nama Repository	BooookScore
URL GitHub	https://github.com/lilakk/BooookScore
Pemilik Repository	lilakk / Yapei Chang dan tim
Jenis Repository	Official code and data release
Keterkaitan Paper	Repository resmi dari paper BooookScore ICLR 2024

Repository BooookScore merupakan repository resmi yang menyediakan code dan data release untuk paper BooookScore. Pada halaman GitHub, repository ini dijelaskan sebagai package untuk menghasilkan ringkasan teks panjang dan mengevaluasi koherensi ringkasan tersebut.

3. Spesifikasi Paper Rujukan Utama

Komponen	Keterangan
Judul Paper	BooookScore: A systematic exploration of book-length summarization in the era of LLMs
Penulis	Yapei Chang, Kyle Lo, Tanya Goyal, Mohit Iyyer
Tahun Terbit	2024
Conference/Jurnal	The Twelfth International Conference on Learning Representations / ICLR 2024
URL Paper	https://arxiv.org/pdf/2310.00785.pdf
Task NLP	Summarization, khususnya book-length summarization
Metode Utama	Large Language Models, prompt-based summarization, hierarchical merging, incremental updating, automatic evaluation metric BooookScore
Hubungan Paper dengan Repository	Repository GitHub BooookScore merupakan official code and data release dari paper tersebut

Paper ini membahas eksplorasi sistematis terhadap summarization untuk teks sangat panjang, khususnya teks berbentuk buku. Permasalahan utama yang diangkat adalah bahwa buku dapat memiliki panjang lebih dari 100.000 token, sehingga tidak selalu dapat langsung dimasukkan ke dalam context window LLM.

Paper ini membandingkan dua workflow utama berbasis prompt, yaitu hierarchical merging dan incremental updating. Selain menghasilkan ringkasan, paper ini juga memperkenalkan BooookScore sebagai metrik evaluasi otomatis untuk mengukur kualitas koherensi ringkasan panjang yang dihasilkan oleh LLM.

4. Spesifikasi Code

Repository BoookScore menggunakan bahasa pemrograman utama Python. Code dalam repository ini disusun sebagai package yang dapat digunakan melalui perintah Python module, misalnya `python -m boookscore.chunk`, `python -m boookscore.summ`, `python -m boookscore.postprocess`, dan `python -m boookscore.score`.

No	Komponen	Keterangan
1	Bahasa Pemrograman Utama	Python
2	Jenis File yang Tersedia	File Python package, file prompt, file pickle dataset, file JSON summaries, README, LICENSE, requirements.txt
3	Folder Utama Repository	annotations, boookscore, data, misc, prompts, summaries
4	Folder Code Utama	boookscore
5	Folder Prompt	prompts
6	Folder Data	data
7	Folder Summaries	summaries
8	File Requirements	requirements.txt
9	Lisensi Repository	MIT License
10	Deskripsi Umum Fungsi Code	Package untuk menghasilkan ringkasan teks panjang dan mengevaluasi koherensi ringkasan menggunakan BoookScore
11	API LLM yang Didukung	OpenAI, Anthropic, Together
12	Metode Summarization	Hierarchical merging dan incremental updating
13	Format Input Utama	Pickle dictionary berisi nama buku dan teks lengkap buku
14	Format Output Utama	JSON berisi nama buku dan hasil ringkasan akhir

Secara umum, code BoookScore digunakan untuk menyiapkan data buku, melakukan chunking teks panjang, menjalankan summarization menggunakan LLM, menggunakan prompt untuk menghasilkan ringkasan, menggunakan metode hierarchical merging dan incremental updating, melakukan post-processing hasil summary, serta menyimpan hasil ringkasan dalam format JSON.

5. Spesifikasi Dataset

Dataset pada repository BoookScore digunakan untuk task book-length summarization, yaitu peringkasan teks buku penuh. Dataset berbentuk file pickle dictionary dengan ekstensi .pkl. Struktur datanya adalah key = nama buku dan value = isi teks lengkap buku. Contoh file dataset yang tersedia dalam repository adalah data/example_all_books.pkl.

No	Komponen	Keterangan
1	Jenis Dataset	Teks buku untuk book-length summarization
2	Format Dataset	.pkl / pickle dictionary
3	Struktur Dataset	Key berupa nama buku, value berupa isi teks lengkap buku
4	Contoh File Dataset	data/example_all_books.pkl
5	Unit Data	Satu data merepresentasikan satu buku penuh
6	Input Proses	Teks lengkap buku
7	Proses Awal	Chunking teks panjang sesuai ukuran chunk
8	Output Summary	File JSON
9	Folder Output Summary	summaries
10	Isi Folder Summaries	Hasil ringkasan dari berbagai model LLM dan metode summarization

Folder summaries berisi file JSON hasil ringkasan dari berbagai model dan konfigurasi, misalnya hasil ringkasan menggunakan metode hierarchical maupun incremental. File yang berakhiran cleaned.json berisi final summaries yang sudah melalui post-processing, sedangkan file yang tidak berakhiran cleaned.json berisi intermediate summaries.

6. Sampling Isi Dataset

Karena dataset BoookScore berbentuk .pkl, isi dataset tidak dapat langsung dibaca seperti file CSV atau Excel. Dataset perlu dibuka menggunakan Python, misalnya dengan library pickle. Secara konseptual, dataset berbentuk dictionary dengan nama buku sebagai key dan isi teks lengkap buku sebagai value.

No	Key / Nama Buku	Value / Isi Data	Penjelasan
1	Judul Buku A	Teks lengkap buku A	Digunakan sebagai input utama untuk proses summarization
2	Judul Buku B	Teks lengkap buku B	Dipotong menjadi beberapa chunk agar dapat diproses oleh LLM
3	Judul Buku C	Teks lengkap buku C	Diproses hingga menghasilkan summary akhir dalam format JSON

Setiap data merepresentasikan satu buku penuh. Nama buku menjadi identifier, sedangkan isi teks buku menjadi input untuk proses summarization. Karena teks buku memiliki ukuran sangat panjang, teks tersebut diproses melalui tahap chunking agar setiap bagian dapat masuk ke context window LLM.

7. Teknik / Cara Kerja

BooookScore bekerja dengan alur utama yang dirancang untuk menangani teks sangat panjang. Input awal berupa file pickle yang berisi dictionary nama buku dan teks lengkap buku. Karena teks buku dapat melebihi context window LLM, teks tersebut terlebih dahulu dipotong menjadi beberapa chunk. Setiap chunk kemudian diberikan kepada LLM menggunakan prompt tertentu agar model dapat menghasilkan ringkasan bagian.

Setelah ringkasan per chunk diperoleh, BooookScore menggunakan dua metode utama. Metode pertama adalah hierarchical merging, yaitu menggabungkan ringkasan-ringkasan kecil secara bertingkat hingga menjadi satu ringkasan akhir. Metode kedua adalah incremental updating, yaitu memperbarui ringkasan secara bertahap ketika chunk baru diproses. Hasil akhir kemudian disimpan dalam format JSON dan dapat dievaluasi menggunakan metrik BooookScore.

No	Tahap	Penjelasan
1	Input Data	Data berupa teks buku dalam file pickle dictionary
2	Chunking	Teks panjang dipotong menjadi beberapa chunk
3	Prompting	Prompt digunakan untuk meminta LLM menghasilkan ringkasan
4	Summary per Chunk	LLM menghasilkan ringkasan untuk setiap bagian teks
5	Hierarchical Merging	Ringkasan kecil digabungkan secara bertingkat menjadi ringkasan akhir
6	Incremental Updating	Ringkasan diperbarui secara bertahap seiring masuknya chunk baru
7	Post-processing	Hasil ringkasan dibersihkan dari artifact tertentu
8	Penyimpanan Output	Summary akhir disimpan dalam format JSON
9	Evaluasi	Summary dapat dievaluasi menggunakan BooookScore

8. Kesesuaian dengan Requirements Tugas

No	Requirement Tugas	Status	Keterangan
1	Memiliki GitHub/repository	Sesuai	Repository tersedia di GitHub: https://github.com/lilakk/BooookScore
2	Memiliki code	Sesuai	Terdapat package Python dalam folder booookscore
3	Memiliki dataset atau contoh data	Sesuai	Terdapat contoh data data/example_all_books.pkl
4	Memiliki paper rujukan utama	Sesuai	Paper ICLR 2024 tersedia di arXiv
5	Paper dan repository saling berhubungan	Sesuai	Repository merupakan official code and data release dari paper BooookScore
6	Task sesuai dengan Summarization	Sesuai	Fokus utama adalah book-length summarization
7	Memakai LLM/prompt methods	Sesuai	Menggunakan LLM dan prompt workflow
8	Rilis dalam 3 tahun terakhir	Sesuai	Paper tahun 2024 dan repository aktif untuk paper ICLR 2024
9	Tidak wajib memakai API berbayar pada tahap 1	Sesuai	Tahap 1 hanya memilih dan menganalisis repository, belum menjalankan program
10	Bisa dipelajari untuk tahap implementasi selanjutnya	Sesuai	Repository memiliki README, requirements, contoh data, prompt, code, dan output summaries

Berdasarkan checklist di atas, repository BooookScore memenuhi requirements Project Tahap 1. Repository ini memiliki hubungan langsung dengan paper rujukan utama, memiliki code, prompt, contoh dataset, serta hasil summary yang dapat digunakan sebagai bahan pembelajaran untuk tahap implementasi berikutnya.

9. Kesimpulan

BooookScore layak digunakan sebagai repository utama untuk Project Akhir Individu DSS Tahap 1 dengan task Summarization. Repository ini sesuai karena membahas book-length summarization menggunakan Large Language Models dan prompt methods. Selain itu, BooookScore memiliki paper rujukan utama yang jelas, yaitu paper ICLR 2024 berjudul BooookScore: A systematic exploration of book-length summarization in the era of LLMs.

Repository ini juga menyediakan code, contoh dataset, prompt, file requirements, lisensi, serta hasil summary dalam format JSON. Alur kerjanya mencakup chunking teks panjang, summarization menggunakan LLM, hierarchical merging, incremental updating, post-processing, dan evaluasi summary menggunakan BooookScore. Dengan demikian, BooookScore merupakan pilihan yang tepat dan relevan untuk dilanjutkan pada tahap implementasi berikutnya.

Daftar Sumber

1. Repository BoookScore: <https://github.com/lilakk/BoookScore>
2. Paper BoookScore ICLR 2024: <https://arxiv.org/pdf/2310.00785.pdf>
3. Folder Data BoookScore: <https://github.com/lilakk/BoookScore/tree/main/data>
4. Folder Prompts BoookScore: <https://github.com/lilakk/BoookScore/tree/main/prompts>
5. Folder Summaries BoookScore: <https://github.com/lilakk/BoookScore/tree/main/summaries>
6. Requirements BoookScore: <https://github.com/lilakk/BoookScore/blob/main/requirements.txt>